

تقرير مشروع التخرج

تحليل المشاعر متعدد اللغات

English + Arabic Fusha + Arabic Shami

1. المقدمة

1.1 خلفية المشروع

(Sentiment) هو أحد تطبيقات معالجة اللغة الطبيعية (NLP) الأكثر استخداما في تحليل آراء العملاء، مراقبة وسائل التواصل، ودعم قرارات الأعمال. تحليل المشاعر (Sentiment Analysis)

1.2 مشكلة البحث

معظم أنظمة تحليل المشاعر تركز على الإنجليزية، بينما اللغة العربية — خاصة الفصحى واللهجات — تفتقر لحلول عملية متكاملة في مشاريع التخرج.

1.3 أهداف المشروع

1. بناء نظام يصنف التعليقات إلى: إيجابي / سلبي / محايد

2. دعم 3 أنماط لغوية: English, Arabic Fusha, Arabic Shami

3. توفير ثقة معايرة (Calibrated Confidence) لكل تنبؤ

4. تمكين التحليل لتعليق واحد أو مجموعة تعليقات

5. شرح قرارات النموذج عبر LIME

2. الأعمال ذات الصلة

| المرجع | الوصف |

|-----|-----|

| TF-IDF + Logistic Regression | Baseline القصيرة

| CalibratedClassifierCV | معايرة احتمالات التنبؤ

| LIME | شرح قرارات النماذج على مستوى الكلمات

| ASTD / ArSentD-LEV | Datasets (للتوسع المستقبلي للمشاعر)

3. منهجية العمل

Input Text

↓

Language Detection (en / ar_fusha / ar_shami)

↓

Preprocessing (normalization, stopwords, emoji tokens)

↓

TF-IDF Vectorization (1-2 grams, 15000 features)

↓

Logistic Regression / Linear SVM (GridSearchCV)

↓

Sigmoid Calibration

↓

Sentiment + Confidence + Explanation (LIME)

4. البيانات

4.1 بيانات التدريب (Synthetic)

- 5000~ جملة مولدة من قوالب متنوعة

- توزيع متوازن على 3 لغات x 3 مشاعر

- Augmentation: مرادفات، هاشتاغ، إيموجي

4.2 بيانات التحقق (Real-style)

- data/real/validation_comments.csv — 35 تعليقاً حقيقياً الشكل

- تستخدم للتقييم الصادق خارج بيانات التدريب الاصطناعية

أكاديمية: الدقة 100% على البيانات الاصطناعية متوقعة لأن الأنماط واضحة. التقييم على validation_comments.csv يعكس أداء أكثر واقعية.
< ملاحظة

5. النموذج والتقييم

5.1 النموذج المختار

- TF-IDF + Logistic Regression (Cross-Validation في F1 أفضل)

- Calibration: Sigmoid, 5-fold

5.2 المقاييس

- Precision, Recall, F1 (macro)

- Confusion Matrix

- ROC Curve (one-vs-rest)

- Calibration Plot

5.3 مقارنة (TF-IDF vs BERT Validation)

| النموذج | Accuracy | Macro F1 |

|-----|-----|-----|

| TF-IDF + LogReg | 0.619 | 0.629 |

| XLM-RoBERTa (BERT) | 0.759 | 0.800 |

> F1 أفضل على التعليقات الحقيقية بـ 14+ نقطة BERT

5.4 التشغيل

python train.py --data data/sentiment_dataset_multilingual.csv

python evaluate.py --data data/real/validation_comments.csv

6. النظام المطور

6.1 الواجهة (Streamlit)

- تبويب تعليق واحد + Word Cloud + LIME

- تبويب مجموعة تعليقات (لصق أو CSV)

6.2 API (FastAPI)

POST /api/v1/analyze — تعليق واحد

POST /api/v1/batch — مجموعة تعليقات

POST /api/v1/batch/upload — رفع CSV

GET /api/v1/health — فحص الحالة

6.3 CLI

```
python analyze.py --text "..."  
python analyze.py --file data/sample_comments.csv
```

7. الابتكار

1. Dialect-Aware Pipeline — تمييز فصحي/شامي
2. Confidence-Aware System — %تحذير عند ثقة > 55
3. LIME Explainability — black box ليس
4. Batch + API + UI — جاهز للاستخدام العملي

8. النتائج

راجع:

- models/model_metadata.json
- models/validation_report.json
- models/plots/

9. التحديات والحلول

التحدي	الحل
قلة البيانات العربية	Synthetic + validation set
دقة 100% مشبوهة	تقييم منفصل على validation
sarcasm	Future work — BERT
سرعة vs دقة	TF-IDF للسرعة، BERT اختياري

10. Future Work

- [] دمج ASTD / ArSentD-LEV
- [] Fine-tune CAMeLBERT
- [] Aspect-Based Sentiment Analysis
- [] Real-time social media monitor
- [] Mobile app

11. الخلاصة

تم بناء نظام متكامل لتحليل مشاعر التعليقات بعدة لغات، مع واجهة API و CLI، وشرح قرارات النموذج، وتقييم واقعي على مجموعة تحقق مستقلة.

المراجع

1. scikit-learn Documentation — Text Classification
2. Ribeiro et al. — "Why Should I Trust You?" (LIME)
3. Arabic Sentiment Analysis Literature (ASTD, ArSentD)